Klasifikasi Spam SMS Berbasis TF-IDF: Perbandingan Logistic Regression dan Linear SVM pada Dataset Super SMS

Oleh:

JULIAN CAESAR EBEN EZER SIMORANGKIR
231111575

HOWARD FARREL HURA
231111644

KEVIN LUTHER KIYOSAKI GULTOM
231111131



PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN
2026

DAFTAR ISI

DAFTAR GAMBAR **3**
DAFTAR TABEL **4**
PEMBAGIAN TUGAS ANGGOTA **5**
BAB 1 PENDAHULUAN DAN PERUMUSAN MASALAH **6**
1.1 Latar Belakang 6
1.2 Tujuan dan Pertanyaan Milestone 1 6
1.3 Masukan, Keluaran, dan Batasan 6
BAB 2 DATASET, EDA, DAN PREPROCESSING **7**
2.1 Dataset dan Pemahaman Data 7
2.2 Exploratory Data Analysis (EDA) dan Temuan Awal 8
2.3 Preprocessing 10
BAB 3 REKAYASA FITUR, MODEL, DAN RANCANGAN EVALUASI **12**
3.1 Feature Engineering Awal 12
3.2 Baseline dan Model Kandidat Awal 12
3.3 Rancangan Evaluasi 13
BAB 4 HASIL EKSPERIMEN DAN RENCANA PASCA-UTS **15**
4.1 Hasil Eksperimen dan Analisis Awal 15
4.2 Dokumentasi dan Rencana Pasca-UTS 20
DAFTAR PUSTAKA **22**
LAMPIRAN **23**
Lampiran 1. Tautan dan Berkas Pengumpulan 23
Lampiran 2. Cuplikan Kode Pembentukan Model dan Fold CV 23

DAFTAR GAMBAR

Gambar 1. Distribusi kelas dan panjang pesan pada data train (histogram ditampilkan sampai persentil ke-99) 9

Gambar 2. Confusion matrix pada data validation (baris = label asli, kolom = prediksi) 16

Gambar 3. Learning curve kandidat Linear SVM berdasarkan jumlah SMS latih per fold 18

DAFTAR TABEL

Tabel 1. Pembagian tugas anggota kelompok 5
Tabel 2. Masukan, keluaran, dan batasan proyek 6
Tabel 3. Kolom sumber dan kolom hasil pengolahan 7
Tabel 4. Jumlah data pada setiap tahap pengeluaran 8
Tabel 5. Statistik panjang pesan (jumlah karakter) pada data train 9
Tabel 6. Pesan dengan dan tanpa URL (http://, https://, www.) pada data train 9
Tabel 7. Langkah preprocessing, alasan, dan buktinya 10
Tabel 8. Konfigurasi baseline dan model kandidat awal 13
Tabel 9. Pembagian data akhir setelah karantina pola lintas bagian 13
Tabel 10. Hasil eksperimen awal: baseline, kandidat, metode validasi, metrik, dan hasil 15
Tabel 11. Rincian metrik validation kedua model 16
Tabel 12. Classification report kandidat Linear SVM pada validation 17
Tabel 13. Macro-F1 train dan validasi per fold 17
Tabel 14. Angka learning curve kandidat Linear SVM 18
Tabel 15. Prediksi kandidat SVM pada tujuh SMS uji manual 19
Tabel 16. Jejak angka dan grafik laporan 20
Tabel 17. Tautan dan berkas pengumpulan 23

PEMBAGIAN TUGAS ANGGOTA

Tabel berikut mencatat pembagian tanggung jawab tiap anggota beserta bagian notebook dan berkas hasil yang dikerjakan.

Tabel 1. Pembagian tugas anggota kelompok

NIM	Nama	Tanggung jawab	Bukti pekerjaan
[231111131, 231111644, 231111575]	[Kevin Luther Kiyosaki Gultom, Howard Farrel Hura, Julian Caesar Eben Ezer Simorangkir]	Perumusan masalah, pemilihan dataset, dan pemeriksaan kualitas data	Notebook bagian 1-3; hasil/preprocessing/
[231111131, 231111644, 231111575]	[Kevin Luther Kiyosaki Gultom, Howard Farrel Hura, Julian Caesar Eben Ezer Simorangkir]	EDA, fitur TF-IDF, serta baseline dan kandidat	Notebook bagian 4-6; hasil/eda/, hasil/model/
[231111131, 231111644, 231111575]	[Kevin Luther Kiyosaki Gultom, Howard Farrel Hura, Julian Caesar Eben Ezer Simorangkir]	Evaluasi, learning curve, uji SMS sendiri, dan penyusunan laporan	Notebook bagian 7-9; hasil/evaluasi/, hasil/learning_curve/, hasil/prediksi_sendiri/

BAB 1 PENDAHULUAN DAN PERUMUSAN MASALAH

1.1 Latar Belakang

Layanan SMS masih dipakai untuk notifikasi bank, kode OTP, dan informasi operator, sehingga kotak masuk pengguna bercampur antara pesan pribadi, pesan layanan resmi, dan spam. Pada dataset yang kelompok kami pakai, spam memuat tawaran pinjaman, undian hadiah, promosi paket data, hingga pesan yang mengarahkan penerima untuk menelepon nomor tertentu atau membuka tautan pendek. Spam yang lolos berisiko merugikan penerima, sedangkan SMS biasa yang keliru ditandai spam bisa membuat pesan penting seperti tagihan atau janji temu terlewat. Karena konsekuensi keduanya berbeda, kedua jenis kesalahan tersebut kami hitung secara terpisah.

1.2 Tujuan dan Pertanyaan Milestone 1

Kelompok kami ingin mengukur seberapa baik model classical machine learning membedakan SMS biasa (ham) dan spam hanya dari isi teks satu pesan. Tiga pertanyaan yang ingin kami jawab pada Milestone 1:

1. Seberapa baik baseline Logistic Regression berbasis TF-IDF kata mengenali spam pada data validasi yang terpisah?
2. Apakah kandidat Linear SVM yang menggabungkan TF-IDF kata dan potongan karakter memberi hasil lebih baik pada pembagian data serta metrik yang sama?
3. Apakah prediksi kandidat ikut berubah saat ejaan pesan disamarkan, misalnya *Discount* menjadi *D1scount*?

1.3 Masukan, Keluaran, dan Batasan

Tabel 2. Masukan, keluaran, dan batasan proyek

Komponen	**Penjelasan**
Unit prediksi	Satu SMS (satu baris dataset)
Masukan	Teks SMS setelah normalisasi Unicode NFKC dan perapian spasi
Target	Label biner: 0 = ham (SMS biasa), 1 = spam
Pendekatan	Text mining dengan klasifikasi biner terawasi (supervised) memakai fitur TF-IDF dan model linear classical machine learning
Batasan	Hanya membaca isi teks. Nomor pengirim, waktu kirim, dan metadata jaringan tidak tersedia di dataset. Bahasa dan ragam pesan mengikuti koleksi Super SMS

Tujuan jangka panjang proyek ini adalah pengklasifikasi spam yang tetap stabil ketika pengirim menyamarkan ejaan kata promosi. Pada tahap UTS, pekerjaan yang sudah selesai mencakup alur pembersihan bebas tumpang tindih kelompok, perbandingan satu baseline dan satu kandidat pada data validasi, serta uji awal pada tujuh SMS. Pengujian sistematis terhadap penyamaran ejaan dan evaluasi pada data test akan dikerjakan setelah UTS (Subbab 4.2.2).

BAB 2 DATASET, EDA, DAN PREPROCESSING

2.1 Dataset dan Pemahaman Data

2.1.1 Sumber Dataset

Kelompok kami memakai Super SMS Dataset dari Salman, Ikram, dan Kaafar (2024) yang dipublikasikan bersama artikel IEEE Access (DOI 10.1109/ACCESS.2024.3364671). Berkas CSV diambil dari repositori GitHub peneliti (*smspamresearch/spstudy*, commit *a0889f3*). Dataset ini menggabungkan beberapa koleksi SMS historis berlabel. Sebelum membaca isi CSV, notebook mencocokkan nilai SHA-256 berkas (*ba825b46…894d3*) agar siapa pun yang menjalankan ulang eksperimen dipastikan memakai berkas sumber yang identik. Salinan CSV disertakan di folder *data/* bersama rujukan ke repositori aslinya.

2.1.2 Struktur Data

Berkas mentah memuat 67.010 baris dengan dua kolom asli, dan satu baris mewakili satu SMS. Saat pemrosesan, notebook menambahkan beberapa kolom bantu untuk melacak nomor baris asal serta menjaga pemisahan pembagian data, sedangkan fitur numerik untuk model dibentuk kemudian melalui TF-IDF pada Subbab 3.1.

Tabel 3. Kolom sumber dan kolom hasil pengolahan

Kolom	Jenis	Arti
SMSes	Kolom sumber	Isi teks SMS mentah
Labels	Kolom sumber (target)	0 = ham, 1 = spam; terdapat 2 baris dengan label kosong
id_baris	Kolom bantu	Nomor indeks baris asal (mulai dari 0) untuk menelusuri hasil prediksi
teks	Hasil pembersihan	Teks setelah normalisasi NFKC dan perapian spasi; kolom ini yang masuk ke TF-IDF
label	Hasil pembersihan	Nilai Labels bertipe bilangan bulat (0 atau 1)
kunci	Kolom bantu	teks huruf kecil (casefold) untuk memeriksa duplikat dan konflik label
kelompok	Kolom bantu	Kunci pola huruf a-z setelah URL/email diseragamkan serta angka, spasi, dan tanda baca dihapus; dipakai khusus mencegah kebocoran pola lintas pembagian
split	Kolom bantu	Penempatan pesan: train, validation, atau test

Pada data mentah terdapat 40.830 baris berlabel ham (0), 26.178 baris berlabel spam (1), dan 2 baris tanpa label. Kelas spam mencakup sekitar 39% data, sehingga akurasi saja kurang peka terhadap kesalahan pada kelas yang lebih sedikit dan kami memilih macro-F1 sebagai metrik utama (Subbab 3.3.3).

2.1.3 Asal Data dan Keterbatasannya

Label mengikuti koleksi-koleksi sumber yang digabungkan peneliti. Kelompok kami tidak melabeli ulang pesan dan tidak memiliki rincian prosedur pelabelan tiap sub-koleksi asal, termasuk apakah seluruh pesan berasal dari lalu lintas SMS nyata atau ada yang telah disunting sebelum dipublikasikan. Sejumlah pesan sudah mengalami anonimisasi dari sumbernya, seperti nomor telepon atau nominal yang diganti *XXXXXXXXXX* dan *XXXX*. Karena itu kesimpulan pada laporan ini hanya berlaku untuk distribusi pesan di dalam Super SMS.

2.1.4 Kualitas Data yang Diperiksa

Pemeriksaan kualitas data mencakup label kosong atau di luar 0/1, teks kosong, byte yang gagal dibaca sebagai karakter utuh, konflik label pada teks yang sama, duplikat setelah normalisasi, serta kemiripan pola pesan antar pembagian data. Rincian perubahan jumlah baris pada tiap pemeriksaan dirangkum pada Tabel 4.

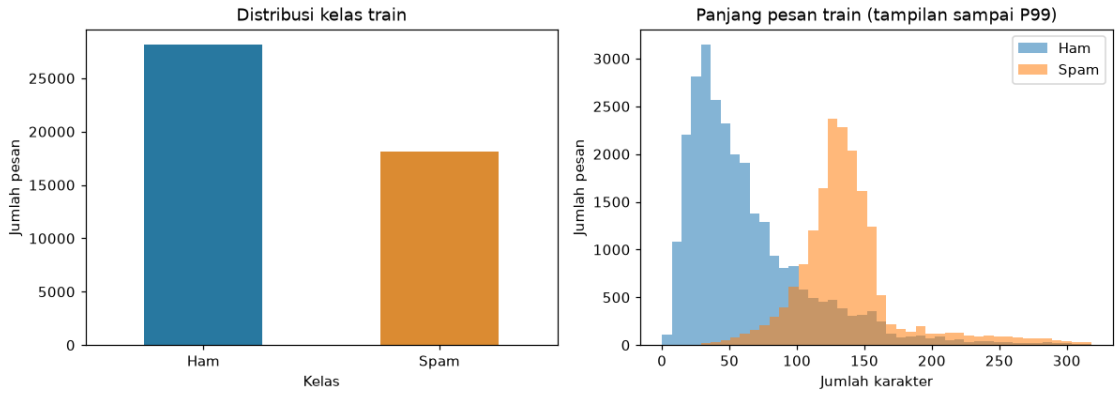
Tabel 4. Jumlah data pada setiap tahap pengeluaran

Tahap pemeriksaan	Dikeluarkan	Sisa baris	Sumber bukti
Data mentah awal	0	67.010	Notebook bagian 2
Label tidak valid (kosong / di luar 0-1)	1	67.009	preprocessing/baris_dikeluarkan.csv
Teks kosong	1	67.008	preprocessing/baris_dikeluarkan.csv
Karakter rusak saat pembacaan (cp1252)	19	66.989	preprocessing/baris_dikeluarkan.csv
Teks identik dengan label bertentangan	0	66.989	Notebook bagian 3
Duplikat teks setelah normalisasi huruf kecil	95	66.894	preprocessing/baris_dikeluarkan.csv
Pola pesan muncul di lebih dari satu pembagian	606	66.288	preprocessing/pola_lintas_split_dikeluarkan.csv

Satu baris dengan label tidak valid (*id_baris* 22) berisi pesan tawaran kartu kredit yang kolom labelnya kosong, sedangkan satu baris teks kosong (*id_baris* 121) memiliki teks sekaligus label kosong. Keduanya menjelaskan dua label kosong yang terlihat saat pembacaan awal.

2.2 Exploratory Data Analysis (EDA) dan Temuan Awal

Eksplorasi data dijalankan khusus pada bagian train (46.301 SMS) agar pemilihan fitur dan metrik tidak dipengaruhi isi validation maupun test.



Gambar 1. Distribusi kelas dan panjang pesan pada data train (histogram ditampilkan sampai persentil ke-99)

2.2.1 Distribusi Kelas

Bagian train terdiri atas 28.181 ham dan 18.120 spam, atau 39,14% spam (Gambar 1 kiri). Pada komposisi ini, penebak pasif yang selalu memilih ham sudah memperoleh akurasi 60,86% tanpa menangkap satu pun spam. Karena itu evaluasi model memakai macro-F1 yang memberi bobot setara bagi F1 ham dan F1 spam, didampingi recall spam serta FP rate ham.

2.2.2 Panjang Pesan

Tabel 5. Statistik panjang pesan (jumlah karakter) pada data train

Kelas	Jumlah	Rata-rata	Std	Min	Q1	Median	Q3	Maks
Ham	28.181	65,6	57,3	3	31	50	82	1.471
Spam	18.120	142,3	57,7	19	118	134	150	2.539

Median panjang spam mencapai 134 karakter (rentang antarkuartil 118-150), lebih dari dua setengah kali median ham sebesar 50 karakter (rentang antarkuartil 31-82). Pada Gambar 1 kanan, puncak sebaran spam berkumpul di kisaran 110-160 karakter mendekati batas satu SMS standar, sementara ham banyak berupa percakapan singkat di bawah 80 karakter. Kendati demikian, kedua kurva masih saling bertumpuk cukup lebar di rentang 80-150 karakter, sehingga panjang teks saja tidak memadai sebagai pemisah kelas. Pola panjang ini merupakan ciri deskriptif pada sampel train, bukan bukti penyebab suatu pesan dikategorikan spam.

2.2.3 Keberadaan URL

Tabel 6. Pesan dengan dan tanpa URL (http://, https://, www.) pada data train

Kelas	Tanpa URL terlihat	Dengan URL terlihat	Persentase dengan URL
Ham	28.168	13	0,05%
Spam	14.057	4.063	22,42%

Pola awalan http://, https://, atau www. ditemukan pada 4.063 spam (22,42%) dan 13 ham (0,05%). Sebanyak 77,58% spam tidak cocok dengan pola ini. Pemeriksaan tersebut hanya mendeteksi tiga awalan URL, sehingga tidak menunjukkan bahwa semua pesan sisanya memakai nomor telepon atau domain pendek. Memblokir seluruh pesan yang cocok dengan pola itu juga akan salah menandai 13 ham. Karena itu, teks tautan tetap dipertahankan agar TF-IDF mempelajari kata dan potongan karakter bersama konteks pesannya.

2.3 Preprocessing

Alur preprocessing memisahkan dua representasi teks. Kolom *teks* menjadi masukan bagi model klasifikasi, sedangkan kolom *kelompok* hanya dipakai pada tahap pembagian data dan cross-validation untuk mencegah salinan template pesan bocor antar bagian.

Tabel 7. Langkah preprocessing, alasan, dan buktinya

Langkah yang dijalankan	Alasan pemilihan	Perubahan data dan bukti
1. Membaca CSV dengan encoding cp1252 dan verifikasi SHA-256	Berkas sumber memuat byte non-UTF-8; pemeriksaan hash memastikan berkas tidak berubah	67.010 baris mentah terbaca; notebook bagian 2
2. Menyisihkan label tidak valid, teks kosong, dan karakter rusak decode	Baris tanpa label 0/1 tidak bisa dilatih; karakter pengganti menandakan isi teks korup saat pembacaan	21 baris dikeluarkan (1 label kosong, 1 teks kosong, 19 rusak decode); preprocessing/baris_dikeluarkan.csv
3. Normalisasi bersihkan(): Unicode NFKC dan perapian spasi	Menyeragamkan variasi karakter Unicode tanpa menghapus angka, tanda baca, dan huruf kapital yang bisa memberi sinyal spam	66.989 baris dinormalisasi; contoh sebelum/sesudah tampil di notebook bagian 3
4. Pemeriksaan konflik label dan penghapusan duplikat (casefold)	Mencegah teks identik berlabel ganda serta menghindari pengulangan baris yang sama di beberapa bagian data	0 konflik label; 95 duplikat disisihkan; tersisa 66.894 baris
5. Pembentukan kunci pola kelompok	Mengenali SMS template yang hanya berbeda angka nominal, tanggal, alamat tautan, spasi, atau tanda baca	URL/email diseragamkan lalu karakter non-a-z dihapus; tersimpan di preprocessing/pembagian_data.csv
6. Pemetaan pembagian_awal.csv dan karantina pola lintas bagian	Jika suatu pola muncul di test, salinannya di train/validation dibuang; jika muncul di validation, salinannya di train dibuang	606 pesan dikarantina (544 dari train, 62 dari validation); tersisa 66.288 pesan di preprocessing/pembagian_data.csv
7. Verifikasi himpunan saling lepas (isdisjoint)	Memastikan secara terprogram tidak ada kunci atau kelompok yang beririsan antar bagian	Pemeriksaan assert lolos untuk pasangan train-val, train-test, dan val-test

Berkas *data/pembagian_awal.csv* menyimpan penempatan awal untuk 66.894 ID pesan (46.845 train, 10.017 validation, dan 10.032 test) sehingga setiap eksekusi ulang

menghasilkan pembagian yang konsisten. Karena kunci *kelompok* pada notebook menyisakan huruf *a-z* rapat tanpa spasi dan tanda baca, kode berhasil menjaring 606 pesan berpola sama yang sebelumnya terpisah. Misalnya *id_baris* 1461 di train ("Im at arestaurant eating squid! … wanna dosomething …") dan *id_baris* 46196 di validation ("Im at a restaurant eating squid! … wanna do something …") hanya berbeda spasi, sehingga salinan pada train dikeluarkan.

2.3.1 Pencegahan Data Leakage

- Antar pembagian train, validation, dan test tidak terdapat irisan *kunci* maupun *kelompok*, dibuktikan lewat *assert isdisjoint()* pada bagian 3 notebook.
- Model hanya menggunakan kolom *teks* yang berasal dari isi SMS itu sendiri tanpa menyertakan informasi yang baru ada sesudah pelabelan.
- Transformasi *TfidfVectorizer* dibungkus di dalam *Pipeline* scikit-learn, sehingga kamus fitur dan bobot IDF pada saat cross-validation dihitung murni dari subset latih di tiap fold. Pada bagian 7 notebook, bobot IDF model akhir dihitung ulang manual hanya dari 46.301 dokumen train dan terverifikasi cocok melalui *np.allclose()* baik untuk 30.000 fitur kata maupun 50.000 fitur karakter.
- Pembagian tiga fold di dalam train menggunakan *StratifiedGroupKFold* berdasarkan kolom *kelompok*, sehingga pesan bertemplate sama di dalam train juga tidak bocor antara lipatan latih dan lipatan validasi.
- Bagian test (10.032 SMS) sama sekali tidak dibaca pada EDA, pelatihan, cross-validation, maupun analisis kesalahan UTS.

Batasan mekanisme ini terletak pada definisi kunci *kelompok*: dua pesan yang menyampaikan maksud serupa dengan pilihan kata berbeda akan menghasilkan deretan huruf *a-z* yang berbeda pula, sehingga tidak dianggap satu kelompok oleh aturan tersebut.

BAB 3 REKAYASA FITUR, MODEL, DAN RANCANGAN EVALUASI

3.1 Feature Engineering Awal

Agar teks dapat diproses oleh pengklasifikasi linear, isi SMS ditransformasikan menjadi vektor bobot TF-IDF (term frequency-inverse document frequency). Potongan teks yang sering muncul dalam satu pesan tetapi jarang tersebar di seluruh korpus latih memperoleh bobot lebih besar.

- Representasi kata (*fitur_kata()*, dipakai baseline dan kandidat): *TfidfVectorizer* dengan *ngram_range=(1,2)*, *min_df=2*, *max_df=1.0*, *max_features=30000*, dan *sublinear_tf=True*. Unigram dan bigram memungkinkan frasa seperti *claim prize* dibedakan dari kemunculan kata *claim* atau *prize* secara terpisah. *min_df=2* menyaring token yang hanya muncul sekali di data latih, sedangkan *sublinear_tf=True* menerapkan skala 1 + log(tf) agar pengulangan satu kata berkali-kali tidak mendominasi vektor pesan.
- Representasi potongan karakter (ditambahkan pada kandidat melalui *FeatureUnion*): *TfidfVectorizer* dengan *analyzer="char"*, *ngram_range=(3,5)*, *min_df=2*, *max_features=50000*, dan *sublinear_tf=True*. Potongan 3-5 karakter tetap menangkap sub-kata termasuk tanda baca dan spasi di sekitarnya; contohnya *discount* dan *d1scount* masih berbagi potongan *cou*, *oun*, serta *count*.

Setelah dipelajari dari 46.301 SMS train, ruang fitur yang benar-benar terbentuk berjumlah 30.000 kolom pada baseline dan 80.000 kolom (30.000 fitur kata ditambah 50.000 fitur karakter) pada kandidat.

Penambahan n-gram karakter diharapkan membantu mengenali variasi ejaan dan singkatan SMS. Skor kandidat pada Subbab 4.1 lebih tinggi, tetapi efek fitur karakter belum bisa dipisahkan karena pengklasifikasi juga berubah dari Logistic Regression menjadi Linear SVM. Pada Subbab 4.1.4, contoh samaran D1scount masih lolos sebagai ham.

3.2 Baseline dan Model Kandidat Awal

Baseline dipakai untuk mengukur seberapa baik spam bisa dikenali hanya dari fitur kata dan pasangan kata memakai model linear standar. Model kandidat menguji apakah penggabungan fitur kata-karakter dengan pemisah margin linear mampu menekan jumlah spam yang lolos sekaligus menjaga SMS biasa tetap aman pada pembagian data yang sama. Sesuai ruang lingkup Milestone 1, perbandingan difokuskan pada dua konfigurasi ini tanpa tuning hyperparameter menyeluruh.

Tabel 8. Konfigurasi baseline dan model kandidat awal

Peran	Model dan representasi	Parameter utama dan alasan pemilihan
Baseline	LogisticRegression + TF-IDF kata (1-2 gram, 30.000 fitur)	C=1.0, solver lbfgs, max_iter=1000, random_state=42. Cepat dilatih pada matriks teks jarang (sparse) dan menjadi acuan dasar klasifikasi biner teks
Kandidat awal	LinearSVC + FeatureUnion TF-IDF kata (30.000) dan karakter 3-5 gram (50.000)	C=1.0, loss squared_hinge, penalti L2, dual="auto", max_iter=5000, random_state=42. SVM linear bekerja efektif pada ruang fitur berdimensi sangat tinggi (80.000 kolom) untuk mencari batas pemisah ber-margin lebar

Seluruh parameter lengkap kedua pipeline tercatat di berkas *hasil/model/konfigurasi.json*, sedangkan objek pipeline terlatih (mencakup TF-IDF dan model) disimpan ke *logistic_regression_kata.joblib* (1,39 MB) dan *svm_kata_karakter.joblib* (3,51 MB).

3.3 Rancangan Evaluasi

3.3.1 Pembagian Data

Tabel 9. Pembagian data akhir setelah karantina pola lintas bagian

Bagian data	Jumlah aktual	Ham	Spam	% spam	Pemakaian pada proyek
Train	46.301 (69,85%)	28.181	18.120	39,14	Pelatihan model, EDA, dan validasi silang 3-fold
Validation	9.955 (15,02%)	6.049	3.906	39,24	Evaluasi pembanding antara baseline dan kandidat pada UTS
Test	10.032 (15,13%)	6.187	3.845	38,33	Belum dievaluasi; disisihkan untuk pengujian satu kali menjelang UAS

Rasio spam terjaga konsisten di kisaran 38,33% - 39,24% pada ketiga bagian setelah pengeluaran 606 pesan berpola lintas bagian (Subbab 2.3).

3.3.2 Metode Validasi

Di dalam data train (46.301 SMS), kami menjalankan 3-fold cross-validation memakai *StratifiedGroupKFold* (*n_splits=3*, *shuffle=True*, *random_state=42*) dengan pengelompokan pada kolom *kelompok*. Setiap lipatan membagi train menjadi sekitar dua pertiga data latih dan sepertiga data validasi lipatan (30.867/15.434 pada fold 1 dan 2, serta 30.868/15.433 pada fold 3) tanpa memecah kelompok pola yang sama. Indeks ketiga fold disimpan sekali ke variabel *folds* lalu diberikan ke kedua model, sehingga baseline dan kandidat dinilai pada pasangan data latih-validasi yang identik.

Sesudah cross-validation selesai, salinan baru tiap pipeline dilatih pada seluruh 46.301 SMS train dan diuji pada 9.955 SMS validation terpisah. Pengaturan *SEED = 42*

mengunci pengacakan pembagian fold, inisialisasi solver model, dan pengambilan sampel kurva belajar.

3.3.3 Metrik Evaluasi

- Macro-F1 (metrik utama): rata-rata tak berbobot dari F1 kelas ham dan F1 kelas spam, dipilih agar kinerja pada kelas spam (sekitar 39%) dan kelas ham (sekitar 61%) dinilai seimbang.
- Precision spam, recall spam, dan F1 spam: recall spam mengukur proporsi spam aktual yang berhasil ditangkap, sedangkan precision spam mengukur ketepatan prediksi spam.
- FP rate ham (*FP / (FP + TN)*): mengukur proporsi SMS normal yang keliru dimasukkan ke spam.
- Accuracy: disertakan sebagai informasi pelengkap keterbacaan umum.

Dalam pembacaan matriks kesalahan pada proyek ini, false positive (FP) berarti SMS ham ditandai sebagai spam dan berpotensi menyembunyikan pesan penting pengguna, sedangkan false negative (FN) berarti SMS spam lolos sebagai ham. Skor pada data train, validasi silang (CV), dan validation terpisah disajikan sendiri-sendiri tanpa menyebut angka validation sebagai hasil test.

BAB 4 HASIL EKSPERIMEN DAN RENCANA PASCA-UTS

4.1 Hasil Eksperimen dan Analisis Awal

Seluruh angka dan grafik pada bagian ini berasal dari eksekusi utuh UTS-Notebook.ipynb (SEED = 42, Python 3.12.14, scikit-learn 1.9.1). Nilai metrik ditampilkan dengan pembulatan empat angka di belakang koma.

4.1.1 Tabel Hasil Eksperimen Awal

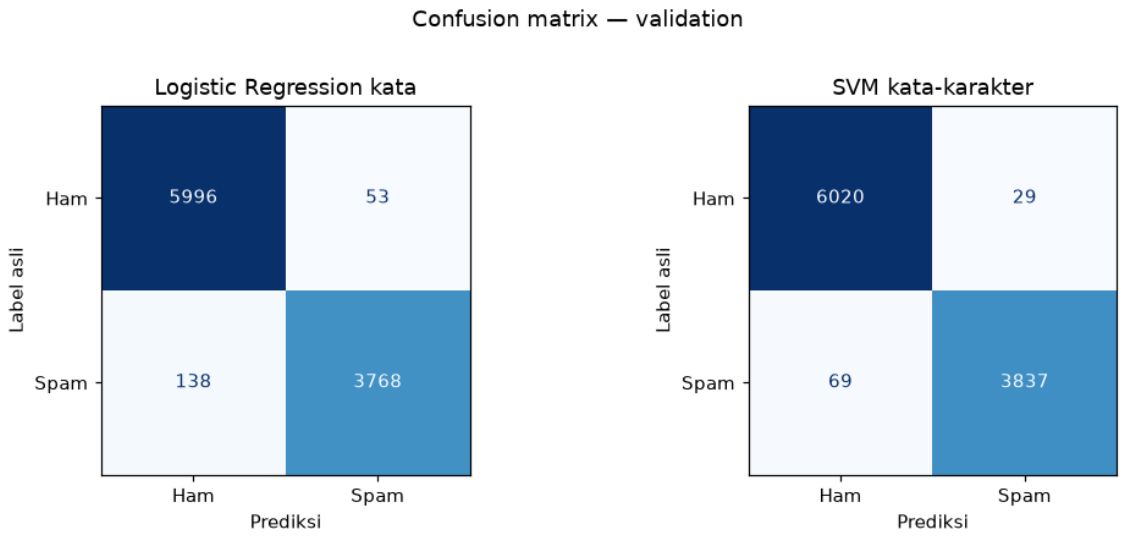
Tabel 10. Hasil eksperimen awal: baseline, kandidat, metode validasi, metrik, dan hasil

Model dan peran	Metode validasi	Metrik	Hasil	Sumber bukti
Baseline · Logistic Regression (TF-IDF kata)	CV 3-fold di train (StratifiedGroupKFold)	Macro-F1 (mean ± std)	0,9820 ± 0,0013	Notebook bagian 6; hasil/evaluasi/hasil_validasi.csv; evaluasi/cv_per_fold.csv
Kandidat · Linear SVM (TF-IDF kata + karakter)	CV 3-fold yang sama di train	Macro-F1 (mean ± std)	0,9909 ± 0,0014	Notebook bagian 6; hasil/evaluasi/hasil_validasi.csv; evaluasi/cv_per_fold.csv
Baseline · Logistic Regression (TF-IDF kata)	Validation terpisah (9.955 SMS)	Macro-F1	0,9798	Notebook bagian 6; hasil/evaluasi/hasil_validasi.csv kolom Macro-F1
Kandidat · Linear SVM (TF-IDF kata + karakter)	Validation yang sama (9.955 SMS)	Macro-F1	0,9897	Notebook bagian 6; hasil/evaluasi/hasil_validasi.csv kolom Macro-F1
Baseline · Logistic Regression (TF-IDF kata)	Validation terpisah (9.955 SMS)	Recall spam / FP rate ham	0,9647 / 0,0088	hasil/evaluasi/hasil_validasi.csv
Kandidat · Linear SVM (TF-IDF kata + karakter)	Validation yang sama (9.955 SMS)	Recall spam / FP rate ham	0,9823 / 0,0048	hasil/evaluasi/hasil_validasi.csv

Tabel 11. Rincian metrik validation kedua model

Metrik pada validation (9.955 SMS)	Baseline LR	Kandidat SVM	Selisih (SVM − LR)
Macro-F1	0,9798	0,9897	+0,0099
Accuracy	0,9808	0,9902	+0,0093
Precision spam	0,9861	0,9925	+0,0064
Recall spam	0,9647	0,9823	+0,0177
F1 spam	0,9753	0,9874	+0,0121
FP rate ham	0,0088	0,0048	-0,0040
Jumlah FP (ham → spam)	53	29	-24
Jumlah FN (spam → ham)	138	69	-69
Jumlah fitur setelah fit	30.000	80.000	+50.000
Waktu fit pada seluruh train (detik)	1,88	9,82	+7,94

4.1.2 Confusion Matrix



Gambar 2. Confusion matrix pada data validation (baris = label asli, kolom = prediksi)

Pada 9.955 SMS validation (6.049 ham dan 3.906 spam), baseline mencatat 53 FP serta 138 FN (total 191 salah prediksi), sedangkan kandidat mencatat 29 FP serta 69 FN (total 98 salah prediksi). Jumlah keempat sel pada masing-masing matriks tepat 9.955 pesan. Beralih dari konfigurasi baseline ke konfigurasi kandidat memangkas spam yang lolos dari 138 menjadi 69 pesan sekaligus menurunkan ham yang salah ditandai spam dari 53 menjadi 29 pesan. Pada kedua model, angka FN tetap lebih besar ketimbang FP, sehingga jenis kekeliruan yang paling banyak tersisa adalah spam yang masih terbaca menyerupai pesan biasa.

Tabel 12. Classification report kandidat Linear SVM pada validation

Kelas	Precision	Recall	F1-score	Support
Ham	0,9887	0,9952	0,9919	6.049
Spam	0,9925	0,9823	0,9874	3.906
Macro avg	0,9906	0,9888	0,9897	9.955
Weighted avg	0,9902	0,9902	0,9901	9.955

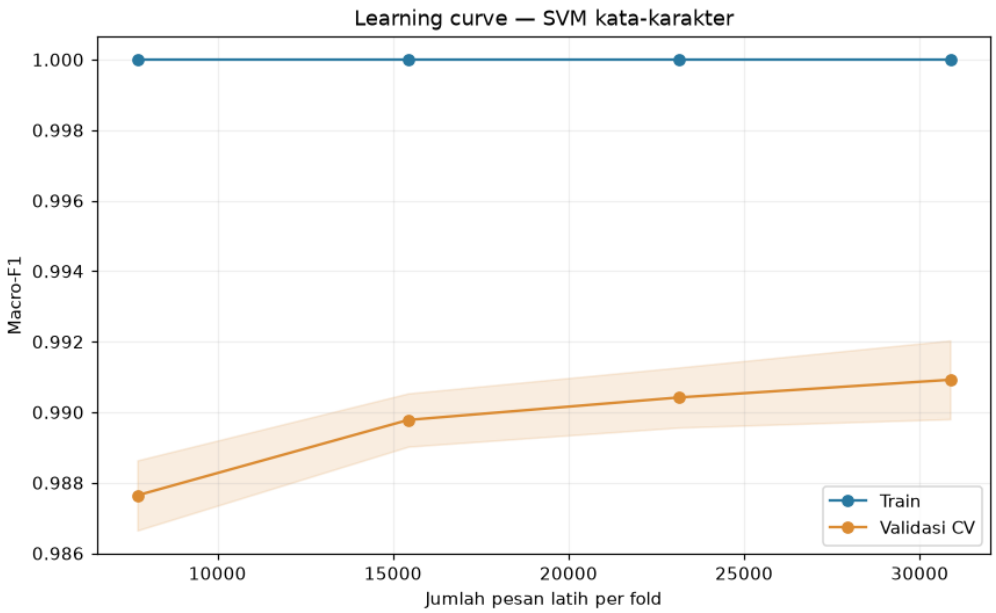
4.1.3 Skor Train, Skor per Fold, dan Learning Curve

Tabel 13. Macro-F1 train dan validasi per fold

Model	Fold	Macro-F1 train	Macro-F1 validasi CV	Selisih
Logistic Regression kata	1	0,9875	0,9827	0,0048
Logistic Regression kata	2	0,9872	0,9829	0,0043
Logistic Regression kata	3	0,9882	0,9805	0,0077
SVM kata-karakter	1	1,0000	0,9909	0,0091
SVM kata-karakter	2	1,0000	0,9923	0,0077
SVM kata-karakter	3	1,0000	0,9895	0,0105

Kandidat SVM memperoleh macro-F1 train 1,0000 di ketiga fold maupun saat dilatih pada seluruh 46.301 SMS train (0 salah klasifikasi). Hal ini terjadi karena kandidat memetakan 46.301 dokumen ke ruang jarang berdimensi 80.000 fitur, sehingga bidang pemisah linear dapat memisahkan seluruh contoh latih. Meski tidak ada label train yang salah ditebak, pemeriksaan fungsi keputusan di bagian 7 notebook menunjukkan 6.300 SMS train (13,6%) masih memiliki margin bertanda di bawah 1 (berada di dalam zona penalti margin SVM).

Skor train sempurna tersebut tidak kami tafsirkan sebagai bukti bebas overfitting. Terdapat selisih train-CV sebesar 0,0077 hingga 0,0105 per fold pada kandidat (dibandingkan 0,0043 hingga 0,0077 pada baseline). Walau celah train-validasi kandidat sedikit lebih lebar, skor validasinya konsisten mengungguli baseline di setiap fold maupun pada validation terpisah.



Gambar 3. Learning curve kandidat Linear SVM berdasarkan jumlah SMS latih per fold

Tabel 14. Angka learning curve kandidat Linear SVM

Jumlah latih per fold	Train mean	Train std	CV mean	CV std
7.716	1,0000	0,0000	0,9876	0,0010
15.433	1,0000	0,0000	0,9898	0,0008
23.150	1,0000	0,0000	0,9904	0,0009
30.867	1,0000	0,0000	0,9909	0,0011

Pada Gambar 3, ukuran latih per fold bertambah dari 7.716 ke 30.867 SMS (25%, 50%, 75%, dan 100% dari ukuran latih terkecil antar-fold). Rata-rata macro-F1 CV naik dari 0,9876 ke 0,9909 (+0,0033), dan selisih terhadap train mengecil dari 0,0124 ke 0,0091. Pita menunjukkan satu simpangan baku. Learning curve melatih ulang model dengan maksimum 30.867 SMS per fold, sedangkan fold ketiga pada CV awal memakai 30.868 SMS (Subbab 3.3.2). Selain itu, NumPy memakai ddof=0 untuk simpangan baku kurva, sedangkan ringkasan CV memakai pandas dengan ddof=1. Jadi, selisih 0,0011 (Tabel 14) dan 0,0014 (Tabel 10) bukan semata-mata perbedaan pembagi pada tiga skor yang identik.

4.1.4 Uji Coba SMS Sendiri

Pengujian di bagian 8 notebook dilakukan terpisah dari evaluasi dataset untuk mengamati perilaku skor keputusan SVM pada pasangan kalimat normal dan kalimat berejaan samaran. Dari tujuh pesan pada Tabel 15, kalimat "Cool. Whats next ?" memang terdapat pada dataset sumber (berada di bagian validation, di luar train), sedangkan enam kalimat lainnya merupakan contoh buatan dengan label harapan berdasarkan skenario uji kelompok kami, bukan ground truth dataset. Skor positif menghasilkan prediksi spam dan skor negatif menghasilkan prediksi ham dengan ambang di nol.

Tabel 15. Prediksi kandidat SVM pada tujuh SMS uji manual

Pesan uji	Prediksi	Skor SVM	Ada di dataset	Ada di train
Cool. Whats next ?	Ham	-1,5476	Ya	Tidak
C00L ! Wh4ts Next?	Ham	-1,3855	Tidak	Tidak
Discount 40% in every product just for today!	Spam	0,1207	Tidak	Tidak
D1scount 40% in every pr0duct just for t0day!	Ham	-0,1760	Tidak	Tidak
Mira, please bring the blue notebook to our meeting at 6:15.	Ham	-0,8047	Tidak	Tidak
M1ra, please br1ng the blue n0tebook to our meeting at 6:15.	Ham	-0,8522	Tidak	Tidak
You have been selected for a free travel voucher. Send your card details to claim it now.	Spam	1,3684	Tidak	Tidak

Kalimat promosi "Discount 40% in every product just for today!" awalnya dikenali sebagai spam tetapi dengan margin tipis (*+0,1207*). Begitu tiga huruf vokal/konsonan diganti angka menjadi "D1scount 40% in every pr0duct just for t0day!", skornya bergeser melewati nol ke *−0,1760* dan berubah menjadi ham, sementara pesan pengingat rapat dan sapaan singkat tetap berada jauh di sisi negatif baik sebelum maupun sesudah disamarkan. Satu kasus buatan ini belum menggambarkan seberapa sering kegagalan serupa terjadi pada populasi data, namun memberi petunjuk awal yang sejalan dengan temuan Salman dkk. (2024) mengenai kerentanan model dangkal terhadap teknik penghindaran teks (*evasive techniques*).

4.1.5 Analisis Perbedaan, Keterbatasan, dan Hal yang Perlu Diperbaiki

- Konfigurasi kandidat meningkatkan macro-F1 dari 0,9820 ke 0,9909 pada CV 3-fold serta dari 0,9798 ke 0,9897 pada validation, memangkas total salah prediksi validasi dari 191 menjadi 98 pesan. Kami tidak mengklaim peningkatan ini signifikan secara statistik karena belum menjalankan uji hipotesis formal.
- Perubahan dari Logistic Regression ke Linear SVM dilakukan bersamaan dengan penambahan 50.000 fitur karakter, sehingga selisih performa di atas merupakan hasil gabungan kedua komponen dan belum dapat diatribusikan ke salah satunya saja.
- Waktu pelatihan pada seluruh data train meningkat dari 1,88 detik (30.000 fitur) menjadi 9,82 detik (80.000 fitur), masih ringan untuk eksekusi CPU lokal.
- Seluruh metrik yang dilaporkan masih berasal dari CV di train dan bagian validation memakai satu nilai *SEED = 42* serta parameter regulasi bawaan *C=1.0*; bagian test (10.032 SMS) belum dievaluasi.
- Sebanyak 98 salah prediksi kandidat pada validation (29 FP dan 69 FN) sudah tersimpan lengkap beserta ID barisnya di *hasil/evaluasi/prediksi_validasi.csv*, tetapi belum dikelompokkan berdasarkan pola kesalahannya, dan ketahanan terhadap ejaan samaran baru diamati pada contoh tunggal di Subbab 4.1.4.

4.1.6 Jejak Angka dan Grafik

Tabel 16. Jejak angka dan grafik laporan

Isi laporan	Rujukan pada hasil notebook (folder hasil/)
Jumlah data per tahap dan pembagian akhir (Tabel 4, Tabel 9)	preprocessing/baris_dikeluarkan.csv, preprocessing/pola_lintas_split_dikeluarkan.csv, preprocessing/pembagian_data.csv; notebook bagian 3
Statistik EDA dan grafik distribusi/panjang (Gambar 1, Tabel 5-6)	eda/eda.png; output notebook bagian 4
Nilai evaluasi utama dan skor per fold (Tabel 10, 11, 13)	evaluasi/hasil_validasi.csv, evaluasi/cv_per_fold.csv; notebook bagian 6
Confusion matrix, laporan per kelas, dan prediksi per SMS (Gambar 2, Tabel 12)	evaluasi/confusion_matrix.png, evaluasi/classification_report.csv, evaluasi/prediksi_validasi.csv; notebook bagian 7
Learning curve (Gambar 3, Tabel 14)	learning_curve/learning_curve.png, learning_curve/learning_curve.csv; notebook bagian 7
Percobaan tujuh SMS sendiri (Tabel 15)	prediksi_sendiri/prediksi_input_sendiri.csv; notebook bagian 8
Parameter pipeline, seed, hash dataset, dan versi pustaka	model/konfigurasi.json, model/logistic_regression_kata.joblib, model/svm_kata_karakter.joblib

4.2 Dokumentasi dan Rencana Pasca-UTS

4.2.1 Dokumentasi Eksperimen

- Notebook eksperimen tersedia di UTS-Notebook.ipynb (10 sel kode dan 12 sel penjelasan). Gunakan kernel Python 3.12, lalu Restart Kernel dan Run All. Sel awal menyiapkan dependensi dari requirements.txt secara otomatis. Petunjuk lengkap ada di README.md; seluruh path mengikuti folder proyek.

- Versi lingkungan eksekusi yang tercatat di *hasil/model/konfigurasi.json*: Python 3.12.14, numpy 2.5.3, pandas 3.0.1, scipy 1.18.1, scikit-learn 1.9.1, matplotlib 3.11.2, ipykernel 7.4.0, nbformat 5.11.1, nbclient 0.11.0, joblib 1.6.0.
- Berkas data di folder *data/*: *super_sms_dataset.csv* (diverifikasi dengan SHA-256) dan *pembagian_awal.csv* (penempatan awal 66.894 ID pesan). Berkas *.gitattributes* menjaga byte baris CSV tetap utuh lintas sistem operasi.
- Pengaturan yang dikunci: *SEED = 42*, validasi silang 3-fold *StratifiedGroupKFold* di dalam train (46.301 SMS), evaluasi pembanding pada validation (9.955 SMS), dan penyimpanan test (10.032 SMS) tanpa disentuh.
- Seluruh keluaran tersimpan per tahap di dalam *hasil/* (*preprocessing/*, *eda/*, *model/*, *evaluasi/*, *learning_curve/*, dan *prediksi_sendiri/*). Menjalankan ulang bagian 8 saja hanya memperbarui berkas di *hasil/prediksi_sendiri/*.

- Pembagian tugas tiap anggota dicantumkan pada Tabel 1. Kelompok kami memakai bantuan AI untuk menyusun kerangka kode dan merapikan laporan. Ide dan pemahaman berasal dari kelompok kami sendiri. Eksekusi notebook serta kesesuaian angka evaluasi kami periksa langsung pada berkas hasil.

4.2.2 Rencana Pengembangan Menuju UAS

Berangkat dari hasil evaluasi dan percobaan ejaan samaran pada Subbab 4.1, berikut rencana pengembangan kelompok kami setelah UTS menuju UAS. Seluruhnya belum diuji pada tahap ini:

1. Kedepannya mungkin kami akan memperluas pengujian pasangan SMS asli dan samaran menggunakan sampel pesan dari bagian validation, lalu menghitung seberapa banyak prediksi pada kelas ham dan spam yang berbalik arah ketika ejaan kata kunci diubah.
2. Kami juga berencana menguji normalisasi ejaan terarah untuk pola seperti *D1scount* menjadi *Discount* dan *pr0duct* menjadi *product* sambil tetap menjaga angka bermakna (seperti *40%*, jam, atau nominal) serta tautan. Dampaknya akan diukur kembali pada validation melalui macro-F1, jumlah spam yang lolos (FN), dan jumlah ham yang salah ditandai (FP).
3. Selain itu, 98 salah prediksi di *prediksi_validasi.csv* akan kami bedah per pola kesalahan sambil meninjau pengaturan parameter yang relevan (seperti nilai *C* atau pemisahan kontribusi fitur kata dan karakter) melalui cross-validation di dalam train.
4. Nantinya setelah satu konfigurasi akhir ditetapkan, kami akan mengevaluasinya satu kali pada 10.032 SMS bagian test yang sejak awal disisihkan, kemudian mendokumentasikan kinerja akhir beserta batasannya untuk laporan UAS.

Dataset dan rumusan masalah ini tetap kami pertahankan hingga UAS. Apabila di tengah pengembangan ditemukan kebutuhan perubahan yang mendasar, kelompok kami akan menyertakan alasan teknisnya dan meminta persetujuan dosen lebih dulu.

DAFTAR PUSTAKA

Salman, M., Ikram, M., & Kaafar, M. A. (2024). Investigating evasive techniques in SMS spam filtering: A comparative analysis of machine learning models. IEEE Access, 12, 24306–24324. https://doi.org/10.1109/ACCESS.2024.3364671

Salman, M., Ikram, M., & Kaafar, M. A. (2024). Super SMS Dataset [Data set]. GitHub: smspamresearch/spstudy, commit a0889f3. https://github.com/smspamresearch/spstudy

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

scikit-learn developers. TfidfVectorizer. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

scikit-learn developers. LinearSVC. https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html

scikit-learn developers. StratifiedGroupKFold. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

scikit-learn developers. learning_curve. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.learning_curve.html

Materi perkuliahan Machine Learning minggu W02, W04, W05, dan W07 (preprocessing, klasifikasi, validasi, dan pembacaan kesalahan).

LAMPIRAN

Lampiran 1. Tautan dan Berkas Pengumpulan

Tabel 17. Tautan dan berkas pengumpulan

Luaran wajib	Lokasi berkas atau bagian laporan
Laporan Milestone 1 PDF	Laporan/UTS-Laporan.pdf
Notebook atau kode dan petunjuk	Folder utama: UTS-Notebook.ipynb, README.md, requirements.txt
Dataset atau petunjuk akses	data/super_sms_dataset.csv dan data/pembagian_awal.csv; sumber asli github.com/smspamresearch/spstudy (commit a0889f3)
Tabel hasil eksperimen awal	Subbab 4.1.1 (Tabel 10 dan 11); hasil/evaluasi/hasil_validasi.csv
Rencana pengembangan pasca-UTS	Subbab 4.2.2 laporan dan bagian 9 UTS-Notebook.ipynb

Lampiran 2. Cuplikan Kode Pembentukan Model dan Fold CV

```
def fitur_kata():
    return TfidfVectorizer(ngram_range=(1,2), min_df=2, max_df=1.0,
                           max_features=30000, sublinear_tf=True)

model = {
    'Logistic Regression kata': Pipeline([('tfidf', fitur_kata()),
        ('model', LogisticRegression(C=1.0, max_iter=1000,
random_state=SEED))]),
    'SVM kata-karakter': Pipeline([('tfidf', FeatureUnion([
        ('kata', fitur_kata()),
        ('karakter', TfidfVectorizer(analyzer='char',
ngram_range=(3,5), min_df=2,
            max_features=50000, sublinear_tf=True))])),
        ('model', LinearSVC(C=1.0, dual='auto', max_iter=5000,
random_state=SEED))])
}
cv = StratifiedGroupKFold(n_splits=3, shuffle=True,
random_state=SEED)
folds = list(cv.split(X_train, y_train, groups=train['kelompok']))
```

Sumber: UTS-Notebook.ipynb bagian 5. Kode utuh dari pembacaan data hingga pengujian input sendiri terdapat di dalam notebook.

Repository kelompok (public)

https://github.com/noitsume/UTS-IF-A-Pagi-A15-Spam-Pesan

Semua path pada Tabel 17 dihitung dari folder utama repository.